

Seasonal Drought Prediction in Africa Utilizing a Combined Statistical and ML Approach

Autor: Simon Lentz

Matrikelnummer: 7374279

E-Mail: simon.lentz@studium.uni-hamburg.de

5. Fachsemester

Institut für Geografie

Universität Hamburg

Betreuende: Olena Dubovyk, Johanna Baehr

Inhaltsverzeichnis

1	Introcution: Hybrid approaches to seasonal drought prediction	1
2	Data and methods	2
2.1	Data	2
2.1.1	The GCFS Seasonal Forecast System	2
2.2	Methods	3
2.3	Daten	4
3	Erwartete Ergebnisse: Verbesserung von saisonalen Vorhersagen und die Überbrückung von Beobachtungs-Vorhersage Lücken	4
4	Geplante Vorgehensweise und Vorläufiger Zeitplan	5
4.1	Summary	5
4.2	Conclusion	5
5	Literatur	7

1 Introcutiion: Hybrid approaches to seasonal drought prediction

Drought is one of the meteorological extreme events that has the greatest impact on agricultural, social, and economic conditions. Extreme droughts occur in almost all climate zones and vary widely in duration, intensity, and regional extent. A distinction can be made between meteorological, agricultural, and socioeconomic droughts. Agricultural and socioeconomic definitions focus on the impacts of meteorological droughts on society. However, the prediction of meteorological drought events even with state-of-the-art global climate models (GCMs) often lacks significant prediction skill. On seasonal time scales, GCMs are mostly used to predict precipitation and temperatures, which are consequently used to calculate drought indices, such as the Standardised Precipitation Evaporation Index (SPEI). Despite huge advancements in seasonal climate predictions in the last decades, climate models still possess significant biases and uncertainties when predicting drought events (Wu u. a., 2022). Especially after the loss of initialization effects, GCMs still show significant errors in their dynamical representation of meteorological droughts (Wu u. a., 2022). In alternative approaches, statistical methods can be used to directly predict the occurrence and intensity of drought events from historical data. However, also statistical models, such as Machine Learning (ML) or regression methods, are limited in their capability to represent nonlinear dynamics reliably (Hao u. a., 2018). While being able to learn and reproduce non-linear dynamics from its training data, ML lacks interpretability and a good representation of overall distributions. In order to combine the strengths of both methods, hybrid approaches based on a mix of GCM prediction and ML postprocessing have recently gotten a lot of attention (Li u. a., 2021; Wu u. a., 2022). Due to the sparse amount of training data and a focus on reliability and explainability, these hybrid approaches often use relatively simple ML models. In comparison to other fields in meteorological or climate research, modern ML techniques like deep neural networks or transformer models seem to be less suited than reliable and cost-efficient solutions like random forest models (Thomasson, 2023; Feng u. a., 2024; Karsisto, 2025). Therefore, this work will also focus on the use of random forest or as an extension boosted decision trees for the postprocessing step. Especially extreme gradient boosting (XGBoost) has shown to be a reliable, efficient and flexible option for forecast postprocessing (Feng u. a., 2024). However, XGBoost has shown to sometimes struggle with extreme outliers and to correct for systematic biases in the variance and distribution of its input data (Feng u. a., 2024). Thus, an intermediate statistical step will be performed. In this step, quantile mapping (QM) matches the original hindcasts distribution to that of the reference data. Since QM cannot by design correct the trend or time evolution of its input data, the combination of QM and XGBoost should be able to account for each others weaknesses. Thus I hope with the framework of QM plus a ML prediction of the remaining residuals to reach an overall significant improvement of the original prediction skill.

Despite the success of ML postprocessing in some fields of climate science, they have not yet been successfully applied to seasonal predictions. Especially the prediction of extreme events, such as droughts,

has only recently gotten more attention in seasonal prediction systems. Thus, there is still significant room for improvement, especially in the postprocessing of these predictions. The DWD for example does not possess an operational seasonal forecast postprocessing including ML techniques to this day. This work tries to close this gap. By combining dynamical predictions of climatic variables on seasonal timescales with a statistical postprocessing step, I will analyse if ML models can be used in order to improve seasonal drought prediction. There are two possibilities to improve drought prediction. Either one can deterministically postprocess an entire prediction of a chosen drought indicator. For this work the SPEI is chosen as a metric for drought severity, including both precipitation and potential evapotranspiration (PET) in its calculation. In this way the postprocessing step aims at improving the overall forecast skill of the SPEI, without specifically targeting the occurrence of drought events. Alternatively, the occurrence of individual extreme drought events can be first extracted from the chosen drought index. Consequently, the ML step can focus on just improving the forecast of these extreme events by either predicting their intensity or by probabilistically predicting the absolute occurrence of a drought event above a certain threshold. In this work both options will be tried out and evaluated in regard to their potential for improvement of prediction quality.

In order to come to an informed conclusion, first an overview of the utilized methods and data will be given in chapter . Both the original dynamical hindcasts and the observational data used for the ML training will be described in detail in section 2.1. The used ML framework as well as additional post- and preprocessing steps will be documented in 2.2. Afterwards, the results of the consequent analysis will be shown in chapter . At last, a summary and conclusion will be drawn in chapter in regard to this hybrid approach's ability to significantly improve the seasonal prediction of drought events.

2 Data and methods

2.1 Data

In the approach utilized in this work two datasets are important. On the one hand, the hindcasts used for the ML training and therefore the input into the postprocessing workflow are the seasonal climate hindcasts by the German Weather Service (DWD). On the other hand, the reference datasets have to be discussed. As a ground truth for the ML training, a mixture of 2 reanalysis datasets based on remote sensing observations have been chosen. The TAMSAT precipitation reanalysis and the ERA5 reanalysis as a surface temperature estimate. In the following section, these datasets, their strengths and limitations as well as current use cases in research will be discussed.

2.1.1 The GCFS Seasonal Forecast System

Since 2016, the DWD is operationally running the current GCFS forecast system. It provides seasonal forecasts up to six months ahead using a fully coupled Earth system model, including atmosphere, ocean, land, and sea ice component (Fröhlich u. a., 2021). GCFS2.0 is based on **MPI-ESM-HR**, increasing atmospheric resolution to **T127 (70 km, 95 levels)** and ocean resolution to **0.4°**,

representing a major upgrade from GCFS1.0. (p.5, lines 123–126)

Initial conditions are generated using **continuous nudging assimilation** toward ERA-Interim atmospheric reanalysis combined with **ORAS5 ocean reanalysis** and decadal assimilation from the MiKlip project. (p.7–8, lines 162–186)

Ensemble forecasts are produced using perturbations in atmospheric parameters and ocean bred vectors, with **30 hindcast members and 50 forecast members**. (p.8–9, lines 187–220)

One major **strength of GCFS2.0** is improved winter forecast skill, particularly for Northern Hemisphere circulation patterns, where **NAO prediction skill approximately doubled** compared to GCFS1.0. (p.21, lines 474–477)

Temperature and geopotential height forecast skill also improved over regions including Alaska, Siberia, northern Europe, and Greenland. (p.15, lines 321–328)

However, **weaknesses remain**, including reduced skill in the tropical Pacific and Atlantic, which negatively affects ENSO prediction. (p.15, lines 337–340; p.21, lines 474–475)

GCFS2.0 also exhibits a **persistent tropical warm bias**, likely related to atmospheric parameterization changes. (p.21, lines 447–468)

Overall, GCFS2.0 improves winter predictability and regional forecast skill, but limitations remain in tropical processes and seasonal-dependent performance. (p.21, lines 470–477)

Since 2020, the DWD uses the German Climate Forecast System (GCFS) for its seasonal predictions.

2.2 Methods

XGBoost is a type of gradient boosting algorithm that builds an ensemble of decision trees sequentially, where each new tree focuses on correcting the errors made by the previous ones. Unlike random forests, which aggregate the predictions of many independent trees, gradient boosting improves prediction accuracy by iteratively minimizing error. (Karsisto, 2025)

In einem hybriden Ansatz sollen in dieser Arbeit die Vorhersagedaten eines dynamischen Klimamodells des DWD mithilfe von KI nachbearbeitet werden. Dafür muss zunächst analysiert werden, in welchen Regionen das dynamische Modell Dürreereignisse mit viel oder wenig Skill vorhersagt. Zur Bewertung des Vorhersageskills sollen einfach statistische Metriken, wie der Root Mean Squared Error (RMSE) oder Pearsons R Korrelation verwendet werden. Anschließend soll ein Partial Convolutional Neural Network (PCNN) die dynamischen Vorhersagen in den Regionen nachbearbeitet werden, in welchen diese als wenig skillvoll gelabelt wurden. Dieses PCNN soll die realistischen Muster von regionalen Dürreextremen auf dem afrikanischen Kontinent mithilfe von hochaufgelösten Remote Sensing Daten lernen. PCNNs stammen ursprünglich aus dem Einfüllen von Fotografien (Liu u. a., 2018). Aufgrund ihrer Fähigkeit räumliche Strukturen zu lernen und auf das Ausfüllen von Lücken anzuwenden, wurden sie allerdings schon häufiger für die Rekonstruktion von Klimadaten verwendet (Kadow u. a., 2020; Lentz u. a., 2025). Dabei werden mithilfe einer binären Maske und einem Input-Bild schrittweise fehlende Werte (Pixel, an denen die Maske 0 anzeigt) mit Werten, die den Traininsdaten an dieser Stelle entsprechen, eingefüllt. Im Kontext dieser Arbeit soll das PCNN die Dürrevorhersagen in den Regionen, in denen sie als schlecht bewertet wurden, mit den aus den Remote Sensing Daten gelernten Strukturen ausfüllen.

Als Predictor für Dürreereignisse soll dabei die klimatische Wasserbilanz

$$KWB = P - PET \quad (2.1)$$

genommen werden. P bezeichnet dabei den totalen Niederschlag pro Quadratmeter, während PET die potentielle Evapotranspiration bezeichnet. Die PET muss dabei zunächst berechnet werden. Mit Penman-Monteith nutzt die state-of-the-art Methode zur Berechnung der PET allerdings viele Input-Größen, welche entweder nicht vorhergesagt werden oder keine Predictability auf saisonalen Zeitskalen besitzen. Aus diesem Grund soll eine einfachere, nur auf der Temperatur basierte Berechnungsmethode der PET in dieser Arbeit verwendet werden. Die KWB bildet damit die Grundlage des SPEI Dürreindizes (Standardised Precipitation Evaporation Index). Da die Nachbearbeitung einer standardisierter Größe allerdings keinen Sinn ergibt, da sie die Standartisierung hinfällig machen würde, wird die unstandardisierte KWB als Zielgröße genutzt werden. Anschließend kann nach dem Postprocessing Schritt durch das PCNN eine Standartisierung vorgenommen werden, um eine globale Vergleichsgröße zu berechnen.

Ausgewertet sollen die Effekte der Nachbearbeitung dann wieder mithilfe von RMSE und Korrelationskoeffizienten, aber auch durch den Vergleich der KWB Distributionen, um ein spezielles Augenmerk auf die wirkungsvollen Ereignisse in den Extremteilen der Distribution zu legen.

Zusätzlich zu der reinen Nachbearbeitung der dynamischen Vorhersagen soll auch versucht werden noch einen Downscaling Mechanismus in das PCNN einzubauen. Durch seine U-net förmige Struktur könnte durch einen weiteren Schritt im Decoder des PCNNs die Auflösung der Inputdaten theoretisch erhöht werden. Durch die Implementierung eines solchen Downscalingmechanismus könnten die niedrig aufgelösten dynamischen Vorhersagen auf die höhere Auflösung der Remote Sensing Daten im Training angehoben werden.

2.3 Daten

Als Datengrundlage für das dynamische Modell sollen die operationellen saisonalen Klimavorhersagen des DWD genutzt werden (Paxian u. a., 2023). Diese sind frei verfügbar und können im Copernicus Data Store frei heruntergeladen werden (Paxian u. a., 2023). Als Grundlage für das Training soll die KWB, berechnet aus höher aufgelösten Remote Sensing Daten verwendet werden. Hierzu soll der totale Niederschlag des TAMSAT-Datensatzes der University of Reading genutzt werden (Maidment u. a., 2020). Dieser ist auf dem afrikanischen Kontinentalgebiet kalibriert und bietet somit die ideale Grundlage für diese Arbeit. Diese sollen für die Berechnung der PET mit den Temperaturdaten der 0.25x0.25 ERA5-Reanalyse kombiniert werden, um die KWB zu berechnen (Soci u. a., 2024).

3 Erwartete Ergebnisse: Verbesserung von saisonalen Vorhersagen und die Überbrückung von Beobachtungs-Vorhersage Lücken

Durch das hybride Nachbearbeiten dynamischer Vorhersagen mithilfe von KI kann eine signifikante Verbesserung des Vorhersageskills der *KWB* und damit auch des *SPEI* erreicht werden. Diese Erwartung zieht sich einerseits aus der statistischen Korrektur von Modellbiase und andererseits, dass die verwendeten PCNN nur auf dem afrikanischen Kontinent kalibriert werden für die Vorhersage der *KWB*. Die ursprünglichen dynamischen Vorhersagen dagegen sind global auf die generelle Vorhersage von Temperatur und Niederschlag kalibriert.

Weiterhin soll versucht werden die Auflösungslücke zwischen Remote Sensing Daten und dynamischen Vorhersagen durch ein möglichen implementierten Downscaling-Mechanismus zumindest verkleinert werden. Dabei ist die Funktion eines solchen Mechanismus aufgrund seiner Neuheit schwer einzuschätzen. Da aber das verwendete PCNN großen Skill in dem ausfüllen von Klimadaten bewiesen hat (Lentz u. a., 2025) und Downscaling im Grunde genommen auch in einem Ausfüllen von neuen Lücken besteht, kann auch hier von einer zumindest einigermaßen realistischen Erhöhung der Vorhersagauflösung ausgegangen werden. In wieweit eine solche höheraufgelöste Vorhersage tatsächlich auch regionale Dürreereignisse besser vorhersagen kann, ist dabei nicht vorher abschätzbar und muss im Arbeitsprozess untersucht werden.

4 Geplante Vorgehensweise und Vorläufiger Zeitplan

4.1 Summary

4.2 Conclusion

Diese Arbeit besteht aus 2 möglichen Schritten. Zunächst sollen die Remote Sensing Daten, sowie die zu verbessernden dynamischen Vorhersagen für den Postprocessing Schritt vorbereitet werden. Dazu sollen die Niederschlags und Temperaturdaten auf eine gemeinsame Auflösung gebracht und aus ihnen die *PET* und schließlich die *KWB* errechnet werden. Anschließend sollen Masken erstellt werden, welche Regionen mit größerem und niedrigerem Vorhersageskill darstellen. Mithilfe der Masken und den vorbereiteten Inputdaten soll dann das PCNN trainiert und mit dem trainierten PCNN die saisonalen *KWB* Vorhersagen des DWD nachbearbeitet werden. Zum Abschluss diesen ersten Teiles soll eine Evaluierung des Effekts, welchen die Nachbearbeitung auf die Vorhersage von Dürreereignissen hat, durchgeführt werden.

Falls diese Analyse im geplanten Zeitrahmen abgeschlossen werden kann, soll anschließend ein Downs-

caling Mechanismus in das PCNN eingebaut werden. Anschließend soll die Analyse des ersten Teils wiederholt werden und mit einem anschließenden Downscaling Schritt, welcher die Vorhersagedaten auf die ursprüngliche Auflösung der Beobachtungsdaten hebt, supplementiert werden. Schließlich sollen die Ergebnisse noch einmal ausführlich evaluiert und in den Kontext anderer Biaskorrekturen oder hybrider Vorhersagemethoden gesetzt werden.

Zeitlich soll die Vorbereitung der Daten in den ersten zwei Wochen nach Bearbeitungsstart abgeschlossen sein. Das anschließende Training und Evaluieren des PCNNs sollte weitere 3-4 Wochen in Anspruch nehmen. Falls dies gelingt soll der zweite Teil der Analyse in weiteren 2-4 Wochen durchgeführt werden. Für das Zusammentragen und Niederschreiben der Ergebnisse werden zum Schluss weitere 2-4 Wochen eingeplant.

5 Literatur


- Feng, S. u. a. (Feb. 2024). „Bias Correction of Tropical Cyclone Intensity for Ensemble Forecasts Using the XGBoost Method“. en. In: *Weather and Forecasting* 39.2, S. 323–332. DOI: 10.1175/WAF-D-23-0159.1.
- Fröhlich, K. u. a. (2021). „The German climate forecast system: GCFS“. In: *Journal of Advances in Modeling Earth Systems* 13.2. Publisher: Wiley Online Library.
- Hao, Z., V. P. Singh und Y. Xia (März 2018). „Seasonal Drought Prediction: Advances, Challenges, and Future Prospects“. en. In: *Reviews of Geophysics* 56.1, S. 108–141. DOI: 10.1002/2016RG000549.
- Kadow, C., D. M. Hall und U. Ulbrich (Juni 2020). „Artificial intelligence reconstructs missing climate information“. en. In: *Nature Geoscience* 13.6, S. 408–413. DOI: 10.1038/s41561-020-0582-5.
- Karsisto, V. (Juli 2025). *Post-Processing Surface Temperature Forecasts with XGBoost*. en. DOI: 10.5194/ems2025-188.
- Lentz, S. u. a. (Jan. 2025). „Improving ocean reanalyses of observationally sparse regions with transfer learning“. en. In: *Scientific Reports* 15.1, S. 2640. DOI: 10.1038/s41598-025-86374-4.
- Li, Y. u. a. (Juli 2021). „Post-processing sub-seasonal precipitation forecasts at various spatiotemporal scales across China during boreal summer monsoon“. en. In: *Journal of Hydrology* 598, S. 125742. DOI: 10.1016/j.jhydrol.2020.125742.
- Liu, G. u. a. (Dez. 2018). *Image Inpainting for Irregular Holes Using Partial Convolutions*. en. arXiv:1804.07723 [cs]. DOI: 10.48550/arXiv.1804.07723.
- Maidment, R. u. a. (2020). „Tamsat“. In: *Satellite Precipitation Measurement: Volume 1*. Springer, S. 393–408.
- Paxian, A u. a. (2023). „The DWD climate predictions website: Towards a seamless outlook based on subseasonal, seasonal and decadal predictions“. In: *Climate Services* 30.
- Soci, C. u. a. (Okt. 2024). „The ERA5 global reanalysis from 1940 to 2022“. en. In: *Quarterly Journal of the Royal Meteorological Society* 150.764, S. 4014–4048. DOI: 10.1002/qj.4803.
- Thomasson, A. (2023). „Improving Visibility Forecasts in Denmark Using Machine Learning Post-processing“. en. Diss. Uppsala, Sweden: Uppsala University.
- Wu, Z. u. a. (Dez. 2022). „Dynamic-LSTM hybrid models to improve seasonal drought predictions over China“. en. In: *Journal of Hydrology* 615, S. 128706. DOI: 10.1016/j.jhydro1.2022.128706.

Erklärung über Selbständiges Verfassen

Ich versichere, dass ich die vorstehende Arbeit selbständig und ohne fremde Hilfe angefertigt und mich anderer als der im beigefügten Verzeichnis angegebenen Hilfsmittel nicht bedient habe. Alle Stellen, die wörtlich oder sinngemäß aus Veröffentlichungen entnommen wurden, sind als solche kenntlich gemacht.

Hamburg, 25.09.2025

Datum, Ort

A handwritten signature in black ink, consisting of a large, stylized 'S' followed by a series of loops and a long horizontal stroke extending to the right.

Unterschrift