

Bachelorarbeitsexposé: Variable Biaskorrekturen (und Downscaling) von saisonalen Dürrevorhersagen in Afrika mit maschinellem Lernen

Autor: Simon Lentz

Matrikelnummer: 7374279

E-Mail: simon.lentz@studium.uni-hamburg.de

5. Fachsemester

Institut für Geografie

Universität Hamburg

Betreuende: Olena Dubovyk, Johanna Baehr

Inhaltsverzeichnis

1	Einleitung: Dürrevorhersagen in Afrika - Die Lücke zwischen Beobachtungsdaten und saisonalen Vorhersagen	1
2	Methoden und Daten: Postprocessen dynamischer Vorhersagen durch Maschinelles Lernen auf Basis von Remote Sensing Daten	2
2.1	Methode	2
2.2	Daten	3
3	Erwartete Ergebnisse: Verbesserung von saisonalen Vorhersagen und die Überbrückung von Beobachtungs-Vorhersage Lücken	3
4	Geplante Vorgehensweise und Vorläufiger Zeitplan	4
5	Literatur	5

1 Einleitung: Dürrevorhersagen in Afrika - Die Lücke zwischen Beobachtungsdaten und saisonalen Vorhersagen

Dürre gehört zu den meteorologischen Extremereignissen, welche den größten Einfluss auf landwirtschaftliche, soziale und ökonomische Verhältnisse hat. Dürreextreme ereignen sich in fast allen Klimazonen und in einer weiten Spanne an Dauer, Intensität und regionaler Ausdehnung.

Unterschieden werden kann dabei zwischen meteorologischen, landwirtschaftlichen und sozioökonomischen Dürren. Landwirtschaftliche und sozioökonomischen Dürredefinitionen berechnen die Auswirkungen meteorologischer Dürreereignisse auf landwirtschaftliche und sozioökonomische Modelle. Meteorologische Dürreereignisse mit signifikantem Skill vorherzusagen, ist dabei nicht einfach. Sie sind hauptsächlich abhängig von Niederschlagsdefiziten und erhöhter Evapotranspiration aufgrund von erhöhten Temperaturen (Hao u. a., 2018). Aus diesem Grund erfolgen Vorhersagen meteorologischer Dürreereignisse meistens mithilfe von dynamischen Klimamodellen (General Circulation Models - GCM). Diese sagen dann die entsprechenden klimatischen Variablen vorher, beispielsweise Niederschlag und Temperatur, aus welchen anschließend Evapotranspiration und schließlich standardisierte Dürreindizes berechnet werden können. Allerdings besitzen alle Klimamodelle signifikante Biase und Unsicherheiten, welche zu verschobenen oder fehlerhaften Dürrevorhersagen führen können (Wu u. a., 2022). Speziell nach dem Abklingen von Initialisierungseffekten können dynamische Klimamodelle auf saisonalen Zeitskalen signifikante Unsicherheiten und fehlerhafte Dynamiken darstellen aufgrund unterliegender Modellbiase (Wu u. a., 2022). Eine alternative Methode zur Vorhersage von Dürreereignissen sind statistische Modelle. Mithilfe der statistischen Analyse historischer Daten können zukünftige Dürreereignisse vorhergesagt werden. Statistische Methoden, wie künstliche Intelligenz (KI), Regressions- oder konditionelle Wahrscheinlichkeitsmodelle, haben allerdings auch klare Schwachpunkte. Speziell in Bezug instabilen und nichtlinearen statistischen Beziehungen sind statistische Vorhersagemodelle limitiert. Zusätzlich führen undurchsichtige Architekturen besonders bei KI-Modellen häufig zu unklaren und inkonsistenten dynamischen Beziehungen (Hao u. a., 2018). Da beide Ansätze unterschiedliche Schwächen und Stärken besitzen, werden bei klimatischen Vorhersagen auf saisonalen bis dekadischen Zeitskalen immer häufiger hybride Ansätze verwendet, welche dynamische Modelle mit statistischen Vorhersagen kombinieren (Li u. a., 2021; Wu u. a., 2022). Gerade bei saisonalen Vorhersagen von Extremereignissen ist die Implementierung von hybriden KI-GCM-Modellen jedoch noch nicht weit vorangeschritten. Eine weitere Lücke in aktueller Forschungsliteratur bezüglich saisonaler Dürrevorhersagen besteht in der Diskrepanz zwischen der Entwicklung dynamischer Modelle und beobachtungszentrierter Forschung zu aktuellen und historischen Entwicklungen von Dürreextremen. Dabei ist nicht nur die Kalibrierung von Klimamodellen auf die akkurate Vorhersage von Extremereignissen ein Problem, sondern auch die unterschiedlichen räumlichen Auflösungen. Aufgrund ihres extrem hohen Rechenaufwands können dynamische GCMs nicht mit der hohen Auflösung von Beobachtungsdaten durch Remote Sensing

mithalten.

In dieser Arbeit soll aus diesen Gründen mit einem hybriden Ansatz zwischen maschinellem Lernen (ML) und dynamischen Klimamodellen versucht werden die saisonale Vorhersage von regionalen Dürreereignissen zu verbessern. Dabei sollen durch das Postprocessen saisonaler dynamischer Vorhersagen mit ML einerseits Biases dynamischer Modelle verbessert werden. Zusätzlich soll durch das Trainieren der ML auf aktuellen und hochaufgelösten Remote Sensing Beobachtungsdaten die Lücke zwischen Beobachtungen und dynamischer Vorhersagen geschlossen werden. Idealerweise soll dadurch die operationelle, dynamische Vorhersage des deutschen Wetterdiensts (DWD) mithilfe einer variablen und statistischen Biaskorrektur verbessert und auf die Vorhersage von Dürreextremen kalibriert werden, sowie auf die Auflösung der Beobachtungsdaten angehoben werden.

2 Methoden und Daten: Postprocessen dynamischer Vorhersagen durch Maschinelles Lernen auf Basis von Remote Sensing Daten

2.1 Methode

In einem hybriden Ansatz sollen in dieser Arbeit die Vorhersagedaten eines dynamischen Klimamodells des DWD mithilfe von KI nachbearbeitet werden. Dafür muss zunächst analysiert werden, in welchen Regionen das dynamische Modell Dürreereignisse mit viel oder wenig Skill vorhersagt. Zur Bewertung des Vorhersageskills sollen einfach statistische Metriken, wie der Root Mean Squared Error (RMSE) oder Pearsons R Korrelation verwendet werden. Anschließend soll ein Partial Convolutional Neural Network (PCNN) die dynamischen Vorhersagen in den Regionen nachbearbeitet werden, in welchen diese als wenig skillvoll gelabelt wurden. Dieses PCNN soll die realistischen Muster von regionalen Dürreextremen auf dem afrikanischen Kontinent mithilfe von hochaufgelösten Remote Sensing Daten lernen. PCNNs stammen ursprünglich aus dem Einfüllen von Fotografien (Liu u. a., 2018). Aufgrund ihrer Fähigkeit räumliche Strukturen zu lernen und auf das Ausfüllen von Lücken anzuwenden, wurden sie allerdings schon häufiger für die Rekonstruktion von Klimadaten verwendet (Kadow u. a., 2020; Lentz u. a., 2025). Dabei werden mithilfe einer binären Maske und einem Input-Bild schrittweise fehlende Werte (Pixel, an denen die Maske 0 anzeigt) mit Werten, die den Trainingsdaten an dieser Stelle entsprechen, eingefüllt. Im Kontext dieser Arbeit soll das PCNN die Dürrevorhersagen in den Regionen, in denen sie als schlecht bewertet wurden, mit den aus den Remote Sensing Daten gelernten Strukturen ausfüllen.

Als Predictor für Dürreereignisse soll dabei die klimatische Wasserbilanz

$$KWB = P - PET \quad (2.1)$$

genommen werden. P bezeichnet dabei den totalen Niederschlag pro Quadratmeter, während PET

die potentielle Evapotranspiration bezeichnet. Die *PET* muss dabei zunächst berechnet werden. Mit Penman-Monteith nutzt die state-of-the-art Methode zur Berechnung der *PET* allerdings viele Input-Größen, welche entweder nicht vorhergesagt werden oder keine Predictability auf saisonalen Zeitskalen besitzen. Aus diesem Grund soll eine einfachere, nur auf der Temperatur basierte Berechnungsmethode der *PET* in dieser Arbeit verwendet werden. Die KWB bildet damit die Grundlage des SPEI Dürreindizes (Standardised Precipitation Evaporation Index). Da die Nachbearbeitung einer standardisierter Größe allerdings keinen Sinn ergibt, da sie die Standardisierung hinfällig machen würde, wird die unstandardisierte KWB als Zielgröße genutzt werden. Anschließend kann nach dem Postprocessing Schritt durch das PCNN eine Standardisierung vorgenommen werden, um eine globale Vergleichsgröße zu berechnen.

Ausgewertet sollen die Effekte der Nachbearbeitung dann wieder mithilfe von RMSE und Korrelationskoeffizienten, aber auch durch den Vergleich der KWB Distributionen, um ein spezielles Augenmerk auf die wirkungsvollen Ereignisse in den Extremteilen der Distribution zu legen.

Zusätzlich zu der reinen Nachbearbeitung der dynamischen Vorhersagen soll auch versucht werden noch einen Downscaling Mechanismus in das PCNN einzubauen. Durch seine U-net förmige Struktur könnte durch einen weiteren Schritt im Decoder des PCNNs die Auflösung der Inputdaten theoretisch erhöht werden. Durch die Implementierung eines solchen Downscalingmechanismus könnten die niedrig aufgelösten dynamischen Vorhersagen auf die höhere Auflösung der Remote Sensing Daten im Training angehoben werden.

2.2 Daten

Als Datengrundlage für das dynamische Modell sollen die operationellen saisonalen Klimavorhersagen des DWD genutzt werden (Paxian u. a., 2023). Diese sind frei verfügbar und können im Copernicus Data Store frei heruntergeladen werden (Paxian u. a., 2023). Als Grundlage für das Training soll die KWB, berechnet aus höher aufgelösten Remote Sensing Daten verwendet werden. Hierzu soll der totale Niederschlag des TAMSAT-Datensatzes der University of Reading genutzt werden (Maidment u. a., 2020). Dieser ist auf dem afrikanischen Kontinentalgebiet kalibriert und bietet somit die ideale Grundlage für diese Arbeit. Diese sollen für die Berechnung der *PET* mit den Temperaturdaten der 0.25x0.25 ERA5-Reanalyse kombiniert werden, um die *KWB* zu berechnen (Soci u. a., 2024).

3 Erwartete Ergebnisse: Verbesserung von saisonalen Vorhersagen und die Überbrückung von Beobachtungs-Vorhersage Lücken

Durch das hybride Nachbearbeiten dynamischer Vorhersagen mithilfe von KI kann eine signifikante Verbesserung des Vorhersageskills der *KWB* und damit auch des *SPEI* erreicht werden. Diese Erwartung zieht sich einerseits aus der statistischen Korrektur von Modellbiase und andererseits, dass

die verwendeten PCNN nur auf dem afrikanischen Kontinent kalibriert werden für die Vorhersage der *KWB*. Die ursprünglichen dynamischen Vorhersagen dagegen sind global auf die generelle Vorhersage von Temperatur und Niederschlag kalibriert.

Weiterhin soll versucht werden die Auflösungslücke zwischen Remote Sensing Daten und dynamischen Vorhersagen durch ein möglichen implementierten Downscaling-Mechanismus zumindest verkleinert werden. Dabei ist die Funktion eines solchen Mechanismus aufgrund seiner Neuheit schwer einzuschätzen. Da aber das verwendete PCNN großen Skill in dem ausfüllen von Klimadaten bewiesen hat (Lentz u. a., 2025) und Downscaling im Grunde genommen auch in einem Ausfüllen von neuen Lücken besteht, kann auch hier von einer zumindest einigermaßen realistischen Erhöhung der Vorhersagauflösung ausgegangen werden. In wieweit eine solche höheraufgelöste Vorhersage tatsächlich auch regionale Dürreereignisse besser vorhersagen kann, ist dabei nicht vorher abschätzbar und muss im Arbeitsprozess untersucht werden.

4 Geplante Vorgehensweise und Vorläufiger Zeitplan

Diese Arbeit besteht aus 2 möglichen Schritten. Zunächst sollen die Remote Sensing Daten, sowie die zu verbessernden dynamischen Vorhersagen für den Postprocessing Schritt vorbereitet werden. Dazu sollen die Niederschlags und Temperaturdaten auf eine gemeinsame Auflösung gebracht und aus ihnen die *PET* und schließlich die *KWB* errechnet werden. Anschließend sollen Masken erstellt werden, welche Regionen mit größerem und niedrigerem Vorhersageskill darstellen. Mithilfe der Masken und den vorbereiteten Inputdaten soll dann das PCNN trainiert und mit dem trainierten PCNN die saisonalen *KWB* Vorhersagen des DWD nachbearbeitet werden. Zum Abschluss diesen ersten Teiles soll eine Evaluierung des Effekts, welchen die Nachbearbeitung auf die Vorhersage von Dürreereignissen hat, durchgeführt werden.

Falls diese Analyse im geplanten Zeitrahmen abgeschlossen werden kann, soll anschließend ein Downscaling Mechanismus in das PCNN eingebaut werden. Anschließend soll die Analyse des ersten Teils wiederholt werden und mit einem anschließenden Downscaling Schritt, welcher die Vorhersagedaten auf die ursprüngliche Auflösung der Beobachtungsdaten hebt, supplementiert werden. Schließlich sollen die Ergebnisse noch einmal ausführlich evaluiert und in den Kontext anderer Biaskorrekturen oder hybrider Vorhersagemethoden gesetzt werden.

Zeitlich soll die Vorbereitung der Daten in den ersten zwei Wochen nach Bearbeitungsstart abgeschlossen sein. Das anschließende Training und Evaluieren des PCNNs sollte weitere 3-4 Wochen in Anspruch nehmen. Falls dies gelingt soll der zweite Teil der Analyse in weiteren 2-4 Wochen durchgeführt werden. Für das Zusammentragen und Niederschreiben der Ergebnisse werden zum Schluss weitere 2-4 Wochen eingeplant.

5 Literatur


- Hao, Z., V. P. Singh und Y. Xia (März 2018). „Seasonal Drought Prediction: Advances, Challenges, and Future Prospects“. en. In: *Reviews of Geophysics* 56.1, S. 108–141. DOI: 10.1002/2016RG000549.
- Kadow, C., D. M. Hall und U. Ulbrich (Juni 2020). „Artificial intelligence reconstructs missing climate information“. en. In: *Nature Geoscience* 13.6, S. 408–413. DOI: 10.1038/s41561-020-0582-5.
- Lentz, S. u. a. (Jan. 2025). „Improving ocean reanalyses of observationally sparse regions with transfer learning“. en. In: *Scientific Reports* 15.1, S. 2640. DOI: 10.1038/s41598-025-86374-4.
- Li, Y. u. a. (Juli 2021). „Post-processing sub-seasonal precipitation forecasts at various spatiotemporal scales across China during boreal summer monsoon“. en. In: *Journal of Hydrology* 598, S. 125742. DOI: 10.1016/j.jhydrol.2020.125742.
- Liu, G. u. a. (Dez. 2018). *Image Inpainting for Irregular Holes Using Partial Convolutions*. en. arXiv:1804.07723 [cs]. DOI: 10.48550/arXiv.1804.07723.
- Maidment, R. u. a. (2020). „Tamsat“. In: *Satellite Precipitation Measurement: Volume 1*. Springer, S. 393–408.
- Paxian, A u. a. (2023). „The DWD climate predictions website: Towards a seamless outlook based on subseasonal, seasonal and decadal predictions“. In: *Climate Services* 30.
- Soci, C. u. a. (2024). „The ERA5 global reanalysis from 1940 to 2022“. In: *Quarterly Journal of the Royal Meteorological Society* 150.764. Publisher: Wiley Online Library, S. 4014–4048.
- Wu, Z. u. a. (Dez. 2022). „Dynamic-LSTM hybrid models to improve seasonal drought predictions over China“. en. In: *Journal of Hydrology* 615, S. 128706. DOI: 10.1016/j.jhydrol.2022.128706.

Erklärung über Selbständiges Verfassen

Ich versichere, dass ich die vorstehende Arbeit selbständig und ohne fremde Hilfe angefertigt und mich anderer als der im beigefügten Verzeichnis angegebenen Hilfsmittel nicht bedient habe. Alle Stellen, die wörtlich oder sinngemäß aus Veröffentlichungen entnommen wurden, sind als solche kenntlich gemacht.

Hamburg, 25.09.2025

Datum, Ort

A handwritten signature in black ink, consisting of a large, stylized 'S' followed by a series of loops and a long horizontal stroke extending to the right.

Unterschrift